

Instrukcja do ćwiczeń laboratoryjnych

Nazwa przedmiotu	Eksploracja danych
Numer ćwiczenia	1
Temat ćwiczenia	Metody redukcji wymiaru: Principal Component Analysis (PCA)

Poziom studiów	II stopień
Kierunek	Data Science
Forma studiów	Stacjonarne
Semestr	1

Wojciech Czech

1. Cel ćwiczenia

- Praktyczne zapoznanie się z liniową metodą redukcji wymiaru PCA
- Przyswojenie pojęć: komponent wiodący, macierz kowariancji, wewnętrzna wymiarowość przestrzeni cech, *biplot*

2. Wprowadzenie do ćwiczenia

Redukcja wymiarowości przestrzeni cech jest są kluczową metodą eksploracji danych. Ma ona na celu wykrycie wewnętrznej wymiarowości danych, usunięcie redundancji i szumów oraz wyodrębnienie cech najbardziej wartościowych z punktu widzenia dyskryminacji danych. Principal Component Analysis (PCA) jest bezparametryczną, liniową metodą redukcji wymiaru szeroko wykorzystywaną w analizie i przetwarzaniu danych w postaci wektorów cech.

3. Przykładowe dane

- <http://home.agh.edu.pl/~czech/vis-datasets/misc/nyt-frame.csv>
Zbiór danych o rozmiarze 101×4433 zawierający 101 wektorów cech reprezentujących artykuły New York Times w dwóch kategoriach: muzyka i sztuka. Wektory cech są znormalizowanymi i przeskalowanymi zgodnie z rankingiem IDF wektorami BoW. Rozmiar słownika wynosi 4433.
- <http://home.agh.edu.pl/~czech/vis-datasets/misc/04cars-data.csv>
Zbiór danych o rozmiarze 387×20 zawierający 386 wektorów cech reprezentujących własności samochodów produkowanych w roku 2004. Pierwsza kolumna zawiera model samochodu, 8 kolejnych kolumn - dane binarne opisujące typ samochodu, następne 11 kolumn dane numeryczne np. moc lub liczba cylindrów.
- <http://vis-www.cs.umass.edu/lfw/>
Zbiór danych Labeled Faces in the Wild (LFW) - benchmarkowy zbiór danych do rozpoznawania twarzy składający się z ponad 13000 zdjęć różnych osób.

4. Przydatne biblioteki i funkcje

1. Pandas: <https://pandas.pydata.org>
 - `csv_read()`
 - `DataFrame`
2. NumPy:
 - `random.choice`
 - `array`
 - `argsort`
3. SciKit Learn:
 - `PCA`
 - `preprocessing.scale`

5. Plan ćwiczenia: analiza zbioru danych New York Times

1. Załaduj zbiór danych NYT jako DataFrame (biblioteka Pandas)

```
import pandas as pd
df = pd.read_csv('./nyt-frame.csv', header = 0)
data = df.iloc[:,9:]
array = data.values
```

2. Wyświetl 20 losowych wybranych elementów słownika (nagłówek)

```
header = list(df.columns.values[9:])
sample_word = np.random.choice(header, 20, replace=False)
print(sample_word)
```

3. Dokonaj transformacji PCA pomijając kolumny, które nie reprezentują słów a jedynie metadane

```
from sklearn.decomposition import PCA
pca = PCA()
X_pca = pca.fit_transform(array)
```


4. Dla pierwszego komponentu wiodącego wyświetl 15 elementów o największej wartości (wraz z nazwami kolumn - słowami). Jakim słowom odpowiadają największe wartości pierwszego komponentu wiodącego?
5. Dla pierwszego komponentu wiodącego wyświetl 15 elementów o najmniejszej wartości (wraz z nazwami kolumn - słowami). Jakim słowom odpowiadają najmniejsze wartości pierwszego komponentu wiodącego?
6. Powtórz eksperyment dla drugiego komponentu wiodącego. Skomentuj uzyskane wyniki.
7. Dokonaj wizualizacji wektorów cech rzutowanych na 2(3) pierwsze komponenty wiodące. Zaznacz dwie klasy (art, music) oddzielnymi kolorami (patrz Rysunek 1).

```
import matplotlib.pyplot as plt
plt.figure()
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=colors, alpha=0.6)
plt.title("PCA projection (NYT)")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.grid(True)
plt.show()
```

8. Narysuj wykres zależności wartości wariancji od numeru kierunku wiodącego k . Jaka część wariancji zostaje zachowana po wykonaniu projekcji na pierwsze 10 komponentów wiodących?

```
variance_ratio = pca.explained_variance_ratio_
plt.plot(variance_ratio, 'ro')
plt.show()
print(sum(variance_ratio[0:10]))
```

9. Skomentuj w jaki sposób inne niż domyślnie wartości argumentów konstruktora `sklearn.decomposition.PCA` mogą być przydatne w rozwiązaniu tego zadania:
 - `n_components`: `None`, `int`, `float`, `'mle'`
 - `copy`
 - `whiten`
 - `svd_solver`: `'auto'`, `'full'`, `'arpack'`, `'randomized'`
10. * Porównaj metody t-SNE oraz UMAP z PCA (wizualizacja 2D). Czy nieliniowe metody (np. UMAP) lepiej separują klasy w danych NYT niż PCA?




Rysunek 1: Rzutowanie na dwa pierwsze komponenty główne dla zbioru danych NYT.

6. Plan ćwiczenia: analiza zbioru danych 04Cars

1. Załaduj zbiór danych 04Cars jako `DataFrame` (biblioteka Pandas) i odfiltruj 11 ostatnich kolumn - zostaną one użyte jako wejście dla PCA.
2. Znormalizuj dane, zapewniając, że dla każdej cechy średnia arytmetyczna wynosi 0, a wariancja 1.
3. Dokonaj transformacji PCA dla wejściowego zbioru danych, a następnie przedstaw zależność bezwzględnej i względnej wartości wariancji od numeru kierunku wiodącego k . Jaka część wariancji zostaje zachowana przy redukcji wymiarowości do 2 i 3 (patrz Rysunek 2)?
4. Wyświetl wartości elementów pierwszego i drugiego komponentu wiodącego wraz z odpowiadającą im nazwą cechy. Co oznaczają elementy o wartości bliskiej zeru? Z jakimi własnościami samochodu wiążą się:
 - Największe elementy pierwszego komponentu wiodącego
 - Najmniejsze elementy pierwszego komponentu wiodącego
 - Największe elementy drugiego komponentu wiodącego
 - Najmniejsze elementy drugiego komponentu wiodącego

```
pc1, pc2 = pca.components_[0:2]
df = pd.DataFrame({
    'Attribute': attributes,
    'PC1': pc1,
    'PC2': pc2
})
```




Rysunek 2: Procent zachowanej wariancji na komponent główny dla zbioru danych 04Cars.

```
}
display(df)
```

	Attribute	PC1	PC2
0	Retail Price	0.263750	0.468509
1	Dealer Cost	0.262319	0.470147
2	Engine Size (l)	0.347080	-0.015347
3	Cyl	0.334189	0.078032
4	HP	0.318602	0.292213
5	City MPG	-0.310482	-0.003366
6	Hwy MPG	-0.306589	-0.010964
7	Weight	0.336329	-0.167464
8	Wheel Base	0.266210	-0.418177
9	Len	0.256790	-0.408411
10	Width	0.296055	-0.312891

5. Dokonaj wizualizacji wektorów cech rzutowanych na 2(3) pierwsze komponenty wiodące. Nanieś tekst z modelem samochodu na wykres. Jakie typy samochodów występują w poszczególnych częściach wykresu?
6. Na tym samym wykresie w 2D przedstaw zbiór danych o zredukowanym rozmiarze wraz z wizualizacją cech rzutowanych na 2 pierwsze komponenty wiodące (*biplot*, patrz Rysunek 3). Co pokazuje tego typu wizualizacja?



Rysunek 3: *Biplot* dla zbioru danych 04Cars.

7. Budowa eigenfaces w oparciu o zbiór danych LFW

1. Korzystając z biblioteki `scikit-learn` wczytaj podzbiór zbioru danych LFW składający się z osób reprezentowanych przez co najmniej 50 różnych zdjęć (`fetch_lfw_people()`). W ten sposób otrzymasz zbiór zdjęć 12 różnych osób.
2. Podziel otrzymany zbiór danych na część treningową i testową (0.7, 0.3)
3. Dla **zbioru treningowego**, oblicz PCA i opierając się na otrzymanych w ten sposób 100 pierwszych komponentach głównych dokonaj redukcji wymiarowości do 100 dla zbioru treningowego i testowego.
4. Korzystając ze zbioru treningowego o zredukowanej wymiarowości, wytrenuj dwa wybrane modele klasyfikacji (np. MLP, SVM, RF, LightGBM) oraz oblicz dokładność klasyfikacji uzyskaną dla każdej z 12 klas na zbiorze testowym. Zamieść w raporcie uzyskane wartości: *precision*, *recall*, *f1-score*. Jak zmieniają się uzyskane wyniki w przypadku redukcji do 50 wymiarów? Wybierz optymalną wymiarowość w oparciu o *scree plot*.
5. Wyświetl 20 pierwszych komponentów głównych (po uprzednim przeskalowaniu) w formie obrazu w skali szarości (*eigenfaces*). W jaki sposób można zinterpretować działanie *eigenfaces* w kontekście redukcji wymiarowości wcześniej nie widzianego zdjęcia (przykładu testowego)? Jakie cechy ekstrahują poszczególne *eigenfaces*?

8. Zadanie dodatkowe: Kernel PCA

1. Przeczytaj artykuł podany w ostatnim punkcie Literatury (Kernel PCA)
2. Korzystając z Kernel PCA z jądrem typu RBF oraz jądrem wielomianowym (parametr jądra dopasowany empirycznie):

- Wykonaj eksperyment opisany w artykule, pokazujący liniową separowalność (w przestrzeni wielowymiarowej zdefiniowanej implícite przez funkcję jądra) punktów reprezentujących powierzchnie dwóch sfer o tym samym środku i różnym promieniu
- Sprawdź czy zastosowanie nieliniowej redukcji wymiaru za pomocą Kernel PCA poprawi wyniki klasyfikacji w zadaniu 7.3, 7.4.

9. Zadania dodatkowe: Incremental PCA

Incremental PCA (IPCA) jest wariantem PCA zaprojektowanym do obsługi danych, które nie mieszczą się w pamięci RAM lub są przesyłane w partiach (np. dane z czujników IoT, logi serwerowe). W przeciwieństwie do klasycznego PCA, IPCA aktualizuje model przyrostowo, co pozwala na efektywne przetwarzanie danych w czasie rzeczywistym. W zadaniu zbadamy, jak:

- Wielkość partii (`batch_size`) wpływa na dokładność IPCA
 - Skalowanie danych oddziałuje na wydajność obu metod
 - Rozmiar zbioru danych determinuje wybór między PCA a IPCA
1. Wygeneruj sztuczny zbiór danych przy użyciu funkcji `make_blobs` z biblioteki `scikit-learn`: 100 000 próbek, 100 cech, 5 skupisk.


```
from sklearn.datasets import make_blobs
X, _ = make_blobs(n_samples=100_000, n_features=100, centers=5)
```
 2. Podziel zbiór danych na treningowy (80%) i testowy (20%)
 3. Znormalizuj dane za pomocą `StandardScaler`
 4. Oblicz PCA na całym zbiorze treningowym i zmierz czas oraz zużycie pamięci
 5. Zapisz wartość wyjaśnionej wariancji dla pierwszych 10 komponentów
 6. Implementacja Incremental PCA
 - Przetwarzaj dane treningowe partiami (np. `batch_size=1000`)
 - Użyj metody `partial_fit()` do aktualizacji modelu
 - Zmierz łączny czas i pamięć użytą przez IPCA
 7. Porównanie wyników:
 - Dla obu metod wyznacz: wariancję wyjaśnioną (`explained_variance_ratio_`), błąd rekonstrukcji (MSE) na zbiorze testowym, czas wykonania i zużycie pamięci
 - Narysuj wykres porównujący wariancję wyjaśnioną przez PCA i IPCA.
 - Skomentuj uzyskane wyniki
 8. Analiza skalowalności:
 - Przeprowadź eksperyment dla różnych rozmiarów zbioru danych (np. 10k, 50k, 100k próbek)
 - Porównaj czas wykonania PCA i IPCA w zależności od rozmiaru danych
 9. Wizualizacja
 - Dokonaj rzutowania danych na 2 komponenty główne za pomocą obu metod
 - Narysuj wykresy rozrzutu i porównaj separację skupisk

10. Pytania:

- Czy wyniki IPCA są zbliżone do PCA pod względem wariancji wyjaśnionej? Uzasadnij.
- Jak zmienia się czas wykonania IPCA w zależności od `batch_size` (np. 100 vs. 5000)?
- W jakich scenariuszach praktycznych warto użyć IPCA zamiast PCA?
- Dlaczego błąd rekonstrukcji może być większy dla IPCA niż dla PCA?

10. Sposób oceny / uzyskania zaliczenia

Na uzyskanie zaliczenia z zajęć laboratoryjnych składa się:

- Wykonanie obowiązkowych zadań na laboratorium oraz przesłanie kodu/sprawozdania za pomocą systemu UPeL lub Teams

11. Literatura

- *Data Mining: The Textbook*, Charu C. Aggarwal, Springer 2015.
- *Data Mining: Concepts and Techniques*, Jiawei Han, Micheline Kamber, Jian Pei, Elsevier 2012, Third Edition.
- *A tutorial on Principal Component Analysis: Derivation, Discussion and Singular Value Decomposition*, Jon Shlens, 2013.
- *Kernel Principal Component Analysis and its Applications in Face Recognition and Active Shape Models*, Quan Wang, <https://arxiv.org/abs/1207.3538>